

Relatório executivo

Síntese do projeto

Estimar preços de imóveis da região de Seattle usando características físicas e indicadores demográficos por CEP. O problema é de regressão: prever um valor contínuo.

Resultado principal

O LightGBM reduziu o MAE em 27,48% frente ao Ridge nas mesmas 4.331 vendas de teste. MAE: USD 74.089,41. MAPE: 12,77%. Cerca de 80,56% das previsões ficaram dentro de $\pm 20\%$ do preço real.

Decisão de uso

Há ganho preditivo, mas o erro permanece relevante e o modelo subestima preços, sobretudo nos imóveis caros. Não existe tolerância de erro aprovada pelo negócio. Os resultados não autorizam precificação automática.

O que foi entregue

Notebooks 01 a 06: análise, preparação, modelagem, avaliação, explicabilidade e 100 previsões. Notebooks 07 e 08: propostas de API, Docker, LLM, MLflow e deploy. Notebook 09: comunicação dos resultados.

Premissa monetária

USD foi adotado pelo contexto de Seattle. A fonte não confirmou explicitamente a moeda e não houve conversão dos valores. Métricas percentuais e R^2 não são valores monetários.

Dados e preparação

Três arquivos originais

Histórico: 21.613 linhas e 21 colunas. Demografia: 70 CEPs e 27 colunas. Exemplos futuros: 100 linhas e 18 características, sem preço observado.

Qualidade e outliers

Não foram encontradas ausências reconhecidas pelo pandas nos arquivos originais. Há 176 IDs repetidos, 13 registros com zero quartos e 10 com zero banheiros. A regra de $1,5 \times \text{IQR}$ sinalizou 1.146 preços extremos, preservados. Mediana resume o centro; não trata outliers.

Merge e variáveis

Junção à esquerda por CEP, muitos-para-um, separadamente para histórico e futuros. Foram acrescentados 26 indicadores. Sete candidatas por linha: presença de porão, ano de reforma registrado, proporção de porão, área por quarto, banheiros por quarto e dois logaritmos de áreas.

Entradas selecionadas

O modelo usa 50 entradas: 18 físicas, sete derivadas e 25 demográficas. `hous_val_amt` foi comparado em grupos e não integra a seleção. O significado e a disponibilidade temporal dos indicadores continuam pendentes.

Limite dos exemplos futuros

Os 100 exemplos coincidem nas características com registros históricos. Demonstram inferência, não generalização independente. Os preços foram previstos pelo modelo, não recuperados por correspondência.

Validação e seleção

Separação temporal

17.191 vendas de treino/validação anteriores a 10/03/2015; 4.331 vendas posteriores no teste. As 91 ocorrências antigas de imóveis presentes no teste foram excluídas. Não há IDs compartilhados entre treino e teste.

Validação cruzada

Três janelas de 45 dias com treino crescente. Quantidades treino/validação: 11.241/2.392; 13.626/1.626; 15.235/1.917. IDs compartilhados são retirados do treino de cada janela. Imputação e codificação aprendem apenas no treino.

Comparação inicial — MAE médio em USD

Ridge: 97.344,71; Random Forest: 69.859,88; XGBoost: 67.780,27; LightGBM: 66.411,63. Todos usam as mesmas 18 entradas físicas nesta comparação.

Escolha e ajuste

Nos dois melhores candidatos, comparamos grupos de entradas. Até 1% acima do menor MAE, preferimos menos colunas; isso não prova equivalência estatística. LightGBM com 50 entradas seguiu para comparação do log do preço e Optuna: oito tentativas, sete completas e uma interrompida.

Configuração final

MAE médio de CV: USD 62.249,43; MAPE médio: 11,97%. Foram 52 ajustes novos e três reaproveitados em 31,65 segundos. Até duas threads; 240,23 MiB amostrados, sem medição exata do pico.

Resultados e significado do erro

Mesmo teste para os dois modelos

Ridge → LightGBM

MAE (USD): 102.170,13 → 74.089,41

MAPE (%): 20,17 → 12,77

RMSE (USD): 172.212,44 → 129.025,96

R² (sem unidade): 0,7805 → 0,8768

Dentro de $\pm 20\%$: 61,37% → 80,56%

Como interpretar

MAE é o tamanho médio do erro em USD; não é máximo por imóvel. MAPE é a média do erro absoluto dividido pelo preço real. RMSE pesa mais os erros grandes. R² não é percentual de acerto.

Percentuais diferentes

MAPE de 12,77% não significa 87,23% de acerto. O erro percentual mediano é 10,03%. A razão entre MAE e preço médio do teste é 13,36% e não é MAPE. O preço médio é USD 554.588,88; a mediana, USD 465.000.

Dentro e fora do treino

MAE: USD 41.185,22 no treino final; USD 62.249,43 na média de validação; USD 74.089,41 no teste. O teste ficou 19,02% acima da validação. Não demonstramos ausência de overfitting; período, composição e otimismo da seleção também podem contribuir.

Aceitabilidade

MAE permanece como critério principal. $\pm 10\%$ e $\pm 20\%$ são faixas descritivas, não tolerâncias aprovadas. MAPE pesa relativamente mais nos imóveis baratos. O menor preço do teste é USD 81.000.

Falhas e explicabilidade

Imóveis caros exigem cuidado

Acima de USD 1 milhão: 315 vendas, MAE de USD 278.380,19, MAPE de 17,39% e 63,81% das previsões dentro de $\pm 20\%$. De USD 300 a 600 mil, essa proporção é 84,57%.

Um caso de falha

O maior erro absoluto foi uma subestimação: preço real de USD 4.208.000 e previsão de aproximadamente USD 2.426.243, erro de 42,34%. Isso não comprova erro no cadastro nem justifica excluir a venda.

Importância global por permutação

Em 600 vendas, com três repetições, latitude, área habitável e grade lideraram o ranking. Localização, tamanho e possível padrão construtivo têm interpretação plausível, mas não demonstram causalidade. Variáveis correlacionadas limitam o ranking.

SHAP local

Foram explicados três exemplos escolhidos por percentis do preço previsto. As contribuições estão em $\log(1 + \text{preço})$. Somar o valor base e as contribuições e aplicar `expm1` reproduz a previsão em USD. Não se deve interpretar diretamente essas contribuições como dinheiro.

Limites das explicações

Três exemplos não representam todos os imóveis. Uma explicação não prova que o preço previsto esteja correto. Baixa importância por permutação não basta para remover uma entrada. Definições dos indicadores ainda precisam de confirmação.

API, Docker e LLM

Proposta, sem implementação

A API receberia 18 características, validaria entradas, juntaria demografia, criaria derivadas e ordenaria 50 entradas para o modelo. Devolveria preço e versões. POST /predict, GET /health e GET /ready são endpoints propostos.

Limite do artefato atual

O joblib contém preparação aprendida e modelo. Merge e criação das sete derivadas continuam externos. A inversão do log já ocorre no TransformedTargetRegressor; a API não deve aplicar expm1 novamente.

Empacotamento e validação

Docker reuniria aplicação, ambiente, modelo e snapshot versionados. Compatibilidade Windows/Linux e bibliotecas nativas precisariam de teste. Nenhuma imagem foi construída; contrato HTTP, carga e reversão não foram testados.


Função da LLM

Uma API de LLM poderia transformar fatos verificados e contribuições locais em explicação acessível. LightGBM continuaria calculando o preço. Sem SHAP para a casa, o texto não atribuiria efeitos a características específicas. Falhas acionariam uma mensagem fixa.

O que não foi medido

Não houve chamada de LLM; exemplos de texto são hipotéticos. A geração não melhora a precisão numérica. Custo, latência, qualidade do texto e limites de consumo precisariam ser medidos antes da ativação.

Deploy e aprendizado contínuo



Aprender com vendas reais

Previsões e preços reais disponíveis alimentariam o monitoramento. Alertas motivariam investigação, não troca automática de modelo. Candidatos seriam treinados separadamente e avaliados em dados posteriores independentes.

Registro e reversão

MLflow Tracking e Model Registry são propostas para experimentos e versões, sem integração executada. A release ligaria também código, contrato, demografia e imagem. Uma reversão restauraria o conjunto completo compatível.

Condição de promoção

Uma versão só substituiria a anterior após avaliação e revisão. O teste atual já foi examinado; repetir ajustes nesse mesmo teste não sustenta uma nova confirmação independente.

Limitações e próximos passos

Limitações principais

A EDA observou todo o histórico antes do split. A disponibilidade temporal da demografia não foi confirmada. Seleção e Optuna usaram as mesmas janelas. O desempenho em um período e região não garante outros cenários. Não foram produzidos intervalos de previsão.

Prioridades

1. Confirmar definições, origem e período dos indicadores.
2. Definir uso, tolerâncias e revisão humana com o negócio.
3. Investigar demografia sem derivadas, complexidade e correção de viés na validação, sem promessa de melhora.
4. Obter dados posteriores independentes para avaliar outra versão.
5. Se o serviço for implementado, verificar equivalência, contrato, carga, monitoramento e reversão.

Fontes da entrega

README e plano; docs/evaluation_summary.md; docs/model_selection_summary.md; docs/executive_summary.md; docs/packaging_api.md; docs/deployment.md; docs/project_audit.md. Métricas e exemplos em reports/metrics; modelos em artifacts; previsões em reports/predictions.

Estado desta revisão

Este PDF consolida os textos revisados e o diagrama simplificado. Substitui a versão anterior de reports/relatorio_executivo.pdf. Os valores vêm dos artefatos salvos; não houve novo treinamento nem alteração de preços previstos.